

Smart Mobility Traffic Analysis

Lucia Simeone
863004095

Claudio Mininno
863004027

Giuseppe Riccio
863004098

Adriano Passaro
863004242

Congestione Urbana: Quando la Città si Blocca

Abstract—Le nostre città sono sempre più affollate: troppe auto, troppe persone, troppo poco spazio. Strade intasate, aria irrespirabile e tempi infiniti nel traffico sono il prezzo che paghiamo per uno sviluppo urbano non sostenibile. La congestione urbana non è solo un disagio... è un campanello d'allarme per il nostro futuro.

I. INTRODUCTION

Il Dataset Smart Mobility Traffic [7] combina dati da reti cybernetico-fisiche e social network per migliorare la gestione intelligente del traffico e la mobilità urbana. Questo set di dati è prezioso per urbanisti, sviluppatori di città intelligenti e ricercatori di intelligenza artificiale che lavorano su soluzioni di mobilità intelligente.

II. CAMPAGNA CRISP-DM

A. Business Understanding

L'obiettivo dell'analisi è migliorare la gestione della mobilità urbana attraverso la previsione delle condizioni del traffico. Questo può supportare decisioni strategiche per ridurre la congestione, ottimizzare le risorse cittadine e migliorare la sostenibilità ambientale.

Domande chiave:

- Quali fattori influenzano maggiormente la congestione del traffico?
- È possibile prevedere il livello di traffico in una determinata area?
- Come il meteo e il parcheggio impattano la mobilità?
- Come il consumo energetico e i livelli di emissioni impattano sulla qualità dell'aria?

Output desiderati:

- Classificazione dello stato del traffico ("Low", "Medium", "High") per individuare zone critiche.
- Regressione per stimare la quantità delle emissioni dei veicoli per verificare le zone con un alto impatto ambientale

B. Data Understanding

In questa sezione viene fornita una panoramica del dataset utilizzato per lo studio della condizione del traffico urbano attraverso l'integrazione di dati provenienti da fonti eterogenee. L'obiettivo è comprendere la natura e la struttura delle variabili disponibili al fine di identificare pattern rilevanti per la successiva fase di modellazione. Le variabili sono suddivise in sei categorie principali:

Mobilità condivisa

- **Ride_Sharing_Demand**: Numero di richieste di ride-sharing
- **Parking_Availability**: Numero di parcheggi disponibili

Tempo e posizione

- **Timestamp**: Data e ora della registrazione
- **Latitude, Longitude**: Posizione geografica

Traffico

- **Vehicle_Count**: Numero di veicoli in un'area
- **Traffic_Speed_kmh**: Velocità media dei veicoli
- **Road_Occupancy_%**: Percentuale di occupazione strada

Condizioni ambientali

- **Weather_Condition**: Condizione meteo (Rain, Snow, Fog, Clear)
- **Emission_Levels_g_km**: Livelli di emissioni
- **Energy_Consumption_L_h**: Consumo energetico per il tratto

Incidentalità e percezione pubblica

- **Traffic_Light_State**: Stato del semaforo
- **Accident_Report**: Presenza di un incidente (0=No, 1=Si)
- **Sentiment_Score**: Analisi del sentiment legata al traffico (da -1 a 1)

Condizione del traffico

- **Traffic_Condition**: Variabile target per classificazione, specifica la categoria (Low, Medium, High)

È importante verificare la qualità dei dati per identificare valori mancanti o incoerenti, soprattutto nei dati geospaziali e meteorologici. Alcuni dati potrebbero richiedere aggregazione per ottenere insight più significativi.

C. Data Preparation

Questa fase è dedicata alla trasformazione del dataset grezzo in una forma adeguata per l'analisi e la modellazione. Una corretta preparazione dei dati è cruciale per garantire l'affidabilità e l'efficacia dei modelli predittivi, riducendo il rischio di bias, overfitting o risultati distorti. Le attività svolte includono:

- Identificazione e gestione dei dati mancanti (es. imputazione o rimozione)
- Rilevamento e trattamento degli outlier
- Analisi della distribuzione delle variabili (es. istogrammi, boxplot)
- Calcolo della correlazione tra variabili numeriche (es. matrice di correlazione, heatmap)

- Codifica delle variabili categoriche (es. One-Hot Encoding, Label Encoding)
- Normalizzazione o standardizzazione delle variabili numeriche per ridurre la varianza di scala tra le feature
- Tecniche di feature engineering per creare nuove variabili rilevanti o trasformare quelle esistenti

D. Modeling

In questa fase sono sviluppati e addestrati modelli di machine learning con l'obiettivo di estrarre conoscenza dai dati e supportare il processo decisionale. Sono state affrontate due tipologie di problemi:

Classificazione dello stato del traffico

- **Obiettivo:** Prevedere lo stato del traffico ("High", "Medium", "Low")
- **Modello utilizzato:** Random Forest Classifier

Regressione per le emissioni dei veicoli

- **Obiettivo:** Stimare i livelli di emissioni per identificare le aree più critiche
- **Modelli utilizzati:** Random Forest Regressor

E. Evaluation

La fase di valutazione è fondamentale per misurare le performance dei modelli sviluppati e per comprendere il loro comportamento su dati non osservati. A seconda del tipo di problema affrontato, sono state adottate metriche diverse, in grado di catturare vari aspetti della qualità predittiva.

Classificazione

- **Metriche utilizzate:**
 - **Accuracy:** misura la percentuale di previsioni corrette
 - **Precision:** quota di predizioni positive corrette sul totale delle predizioni positive
 - **Recall:** quota di predizioni positive corrette sul totale dei reali positivi
 - **F-measure (F1 Score):** media armonica tra precision e recall
 - **Matrice di confusione:** visualizzazione degli errori di classificazione per ciascuna classe

Regressione

- **Metriche utilizzate:**
 - **Mean Absolute Error (MAE):** errore medio assoluto tra valori reali e predetti
 - **Root Mean Squared Error (RMSE):** radice quadrata dell'errore quadratico medio
 - **R² score:** coefficiente di determinazione che misura la bontà dell'adattamento del modello

F. Deployment

La fase di deployment rappresenta il momento in cui i modelli analitici vengono integrati in sistemi reali per generare valore operativo. Per rendere operative le analisi sviluppate, si possono implementare le seguenti soluzioni:

- **Dashboard interattive:** monitoraggio in tempo reale del traffico, con visualizzazioni aggiornate dinamicamente. È

stata realizzata, in particolare, una mappa che evidenzia le aree urbane con i livelli di inquinamento più elevati, utile per l'individuazione delle zone critiche.

- **API predittive:** fornitura di previsioni sul traffico e sulla mobilità accessibili in tempo reale da parte di servizi di trasporto pubblico o privato.
- **Supporto alle decisioni urbane:** utilizzo dei modelli per ottimizzare infrastrutture, gestire il traffico in modo proattivo e ridurre i congestionamenti.

Impatto atteso: l'implementazione di queste soluzioni può migliorare l'efficienza della circolazione urbana, ridurre le emissioni inquinanti e contribuire in modo significativo alla qualità della vita nelle città.

III. ML CANVAS

A. Prediction Task

Una componente centrale di questo lavoro riguarda lo sviluppo di modelli predittivi a supporto della gestione del traffico e della pianificazione della mobilità urbana. Attraverso l'impiego di tecniche di apprendimento supervisionato, l'obiettivo è estrarre conoscenza dai dati disponibili e generare previsioni su diversi aspetti rilevanti:

- **Classificazione del livello di traffico:** previsione dello stato del traffico in aree specifiche, con classi definite come *Low*, *Medium* o *High*.
- **Previsione delle emissioni veicolari:** stima dell'impatto ambientale generato dal traffico in termini di emissioni, con l'obiettivo di identificare le aree critiche.

Tali previsioni possono essere utilizzate sia in contesti di monitoraggio in tempo quasi reale, sia per analisi storiche e pianificazioni strategiche volte all'ottimizzazione della mobilità urbana.

B. Decision

I risultati ottenuti dai modelli predittivi possono essere impiegati da diversi attori istituzionali e tecnologici al fine di supportare decisioni operative e strategiche nel contesto della mobilità urbana. I principali destinatari delle previsioni sono:

- **Autorità del traffico e pianificatori urbani,** possono utilizzare le informazioni previsionali per ottimizzare la gestione della viabilità, ridurre gli ingorghi e pianificare interventi infrastrutturali mirati.
- **Applicazioni di navigazione e servizi di mobilità,** possono integrare i dati predetti per fornire agli utenti informazioni aggiornate su traffico, tempi di percorrenza e percorsi alternativi.
- **Enti e istituzioni ambientali,** che possono monitorare l'evoluzione delle emissioni, identificare le aree a maggiore impatto e adottare politiche di mitigazione ambientale.

L'integrazione di queste previsioni nei processi decisionali contribuisce a migliorare l'efficienza del sistema di trasporto urbano, promuovere la sostenibilità ambientale e offrire un'esperienza di mobilità più sicura e informata per i cittadini.

C. Value Proposition

L'adozione di un sistema predittivo basato su tecniche di apprendimento automatico applicate ai dati di mobilità urbana apporta benefici concreti in diversi ambiti della gestione del traffico e della pianificazione urbana. I principali vantaggi includono:

- **Riduzione del traffico e dei tempi di percorrenza:** grazie alla possibilità di prevedere situazioni di congestione, è possibile supportare una pianificazione più efficiente delle rotte, riducendo così ritardi e sovraccarichi infrastrutturali.
- **Ottimizzazione della mobilità urbana:** l'analisi predittiva consente di individuare aree critiche e di intervenire proattivamente sulla regolazione dei flussi veicolari, migliorando la distribuzione del traffico nelle diverse zone della città.
- **Monitoraggio ambientale:** la stima delle emissioni veicolari permette di identificare zone ad alto impatto ambientale e di supportare l'adozione di misure di mitigazione, contribuendo alla sostenibilità e al miglioramento della qualità dell'aria.

Nel complesso, il valore generato da un tale sistema si riflette in un miglioramento dell'efficienza urbana, in un supporto più solido alle decisioni istituzionali e in una maggiore qualità della vita per i cittadini.

D. Data Collection

La qualità dei dati rappresenta un elemento cruciale per l'efficacia dei modelli predittivi sviluppati. La raccolta dei dati avviene attraverso le seguenti fonti principali:

- **Sensori IoT e dispositivi connessi:** installati nelle infrastrutture urbane, forniscono dati in tempo reale relativi a flussi di traffico, velocità media, condizioni stradali e ambientali.
- **Social network:** offrono dati complementari generati dagli utenti, come segnalazioni di incidenti, congestioni o eventi anomali, contribuendo ad arricchire il contesto informativo e a migliorare la copertura spaziale.

Per garantire previsioni affidabili, è essenziale assicurare la qualità, la completezza e l'aggiornamento continuo dei dati raccolti. A tal fine, vengono adottate tecniche di pulizia, normalizzazione e integrazione, al fine di costruire una base informativa robusta su cui applicare le tecniche di apprendimento automatico.

E. Data Sources

Le principali fonti di dati utilizzate per la costruzione del sistema predittivo derivano da:

- **Cyber-Physical Networks, CPNs:** capaci di raccogliere informazioni in tempo reale su traffico, condizioni ambientali e sicurezza stradale.
- **Social network :** piattaforme digitali da cui vengono estratti dati generati dagli utenti, come segnalazioni di incidenti, che forniscono un contributo dinamico e geolocalizzato all'analisi del traffico.

F. Impact Simulation

Per valutare l'efficacia operativa dei modelli predittivi sviluppati, è necessario simulare e analizzare l'impatto delle previsioni sul sistema di mobilità urbana. Questo processo si articola in diverse fasi:

- **Validazione su dati storici:** i modelli vengono testati su serie temporali passate per misurarne l'accuratezza.
- **Analisi degli errori e dei casi critici:** si valutano le conseguenze di previsioni errate, con particolare attenzione agli scenari in cui un errore di stima potrebbe peggiorare la congestione piuttosto che ridurla.
- **Considerazioni etiche ed equità urbana:** si analizzano possibili bias nei dati e nei modelli, al fine di evitare che alcune zone o comunità urbane siano svantaggiate dalle decisioni automatizzate basate sulle previsioni.

Un modello efficace dovrebbe contribuire alla promozione di una mobilità urbana più sostenibile ed equa.

G. Making Prediction

La frequenza e la modalità con cui vengono generate le previsioni rappresentano un aspetto cruciale per garantire l'utilità operativa del sistema. A seconda del contesto applicativo, è possibile distinguere due principali scenari di utilizzo:

- **Previsioni in tempo reale:** le informazioni vengono aggiornate a intervalli brevi, per consentire interventi immediati sulla gestione del traffico o per fornire indicazioni puntuali agli utenti in movimento.
- **Analisi periodiche:** l'aggiornamento avviene su base oraria o giornaliera, con l'obiettivo di identificare pattern ricorrenti, monitorare l'evoluzione della mobilità e supportare la pianificazione strategica di lungo periodo.

H. Building Model

Per rispondere agli obiettivi predittivi individuati, sono stati sviluppati due modelli distinti, ciascuno progettato per affrontare una specifica tipologia di previsione:

- **Modello di classificazione:** utilizzato per prevedere lo stato del traffico in una determinata area, categorizzandolo in tre classi: *Low*, *Medium*, *High*.
- **Modello di regressione (emissioni):** finalizzato alla previsione del livello di emissioni inquinanti generate dal traffico veicolare, al fine di identificare le aree urbane a maggiore impatto ambientale.

I. Features

Le principali *features* identificate nel nostro dataset, con relativo tipo di dato, includono:

- **Timestamp (datetime)**
- **Latitude (float) e Longitude (float)**
- **Vehicle_Count (int)**
- **Traffic_Condition (int)**
- **Traffic_Light_State (int)**
- **Traffic_Speed_kmh (float)**
- **Road_Occupancy (float)**
- **Energy_Consumption_L_h (float)**
- **Weather_Condition (int)**

- **Emission_Levels_g_km** (float)
- **Accident_Report** (int)
- **Sentiment_Score** (float)

Queste features vengono preprocessate e aggregate su finestre temporali per costruire i vettori di input da fornire ai modelli predittivi.

J. Monitoring

La valutazione delle prestazioni dei modelli predittivi è un aspetto essenziale per garantirne l'affidabilità e l'efficacia nel tempo. A tal fine, vengono adottate metriche specifiche in funzione della natura del problema affrontato:

- **Modello di classificazione (stato del traffico):** le previsioni vengono valutate attraverso indicatori standard del dominio del machine learning, quali Accuracy, Precision e F1-score.
- **Modelli di regressione (velocità e emissioni):** le performance vengono valutate con metriche quantitative continue, quali MEA, MSE e R^2 score

Il monitoraggio di queste metriche consente di rilevare tempestivamente eventuali cali di performance, guidando l'aggiornamento e il riaddestramento dei modelli.

IV. BACKGROUND E LAVORI CORRELATI

L'analisi del traffico è un tema centrale nella pianificazione urbana e nei sistemi intelligenti di trasporto (ITS). Negli ultimi anni, l'utilizzo di tecniche basate sui dati ha permesso di affrontare problemi complessi come la previsione del traffico, la rilevazione di anomalie e l'ottimizzazione dei flussi stradali.

Nel campo dell'apprendimento non supervisionato, tecniche di clustering come k-means e DBSCAN sono state utilizzate per segmentare i pattern di traffico [3]. Inoltre, modelli basati su grafi come le Graph Neural Networks (GNNs) hanno recentemente attirato l'interesse per la loro capacità di modellare reti stradali complesse [6].

Tuttavia, pochi lavori hanno esplorato l'integrazione di dati eterogenei, come dati meteo, eventi pubblici o flussi social (es. Twitter), all'interno dei modelli predittivi. Questo rappresenta un'opportunità per l'utilizzo di tecniche di fusione dati multi-sorgente, potenzialmente in grado di migliorare l'accuratezza e la robustezza delle previsioni.

Inoltre, metodologie come il Reinforcement Learning per il controllo adattivo del traffico o l'uso di modelli agent-based rimangono ancora poco adottate nei sistemi di previsione real-time. Questi approcci potrebbero fornire alternative scalabili e dinamiche per una gestione più efficiente della mobilità urbana.

V. RESEARCH/SOLUTION DESIGN

A. Dataset Specification

Il dataset analizzato, `smart_mobility_dataset.csv`, contiene informazioni relative a mobilità urbana, traffico, meteo, incidenti e percezione pubblica. Sono presenti sia variabili numeriche che categoriche.

B. Data Engineering

L'analisi preliminare è iniziata con il controllo:

- Dei valori nulli (`isnull()`)
- Delle statistiche descrittive (`describe()`)
- Dei tipi di dati delle colonne (`dtypes`)

Dall'analisi preliminare risulta che il dataset è composto da 15 variabili indipendenti e da un totale di 5000 osservazioni. Non sono stati riscontrati valori mancanti in nessuna delle feature. Alcune variabili di tipo categorico saranno successivamente convertite in rappresentazioni numeriche per consentire un'adeguata elaborazione algoritmica. Abbiamo analizzato le distribuzioni statiche delle feature per verificare la presenza di

- eventuali outliers che possono influenzare il modello
- eventuali feature costanti che non ci forniscano alcun contenuto informativo
- variabili eccessivamente correlate fra loro che rappresentino la stessa informazione

Istogrammi per la distribuzione delle feature numeriche




Fig. 1. Distribuzione delle feature numeriche

Come si può notare dai grafici Fig. 1 che le feature sono ben distribuite

Si osserva Fig. 2 che le feature associate a `Traffic_Condition` presentano distribuzioni differenti in corrispondenza delle classi Low, Medium e High. Poiché si tratta della variabile target, non è possibile rimuoverla dal dataset.

Dai grafici non ci sono particolari valori anomali Fig. 3. Successivamente, è stata effettuata la codifica delle variabili categoriche con `LabelEncoder`, e lo scaling delle variabili numeriche è stato eseguito tramite `MinMaxScaler` per normalizzare l'intervallo dei dati.




Fig. 2. Distribuzione delle feature categoriche




Fig. 3. Boxplot delle feature numeriche

Matrice di correlazione

La **matrice di correlazione** consente di:

- Identificare le relazioni lineari tra le feature, dove valori prossimi a 1 o -1 indicano rispettivamente una forte correlazione positiva o negativa.
- Individuare possibili ridondanze: feature fortemente correlate possono essere rimosse al fine di ridurre la dimensionalità del dataset e migliorare la capacità di generalizzazione dei modelli predittivi.
- Evidenziare pattern nascosti nei dati, che possono influenzare la selezione delle variabili da utilizzare nella fase di modellazione.

La rappresentazione grafica Fig. 4 mediante *heatmap* facilita l'immediata individuazione delle correlazioni più rilevanti, grazie all'utilizzo di una scala cromatica e all'annotazione dei valori all'interno della matrice.

C. Feature Engineering

Sono state applicate diverse trasformazioni al dataset per estrarre informazioni temporali rilevanti, calcolare nuove variabili derivate e normalizzare i dati, al fine di migliorare




Fig. 4. Matrice di correlazione

la rappresentazione delle caratteristiche per la modellazione predittiva.

- **Estrazione di componenti temporali:** La colonna Timestamp è stata convertita in formato datetime per consentire l'estrazione di variabili temporali quali il giorno della settimana (DayOfWeek), il flag Is_Weekend (identificando i fine settimana), il giorno del mese (Day), il mese (Month) e l'ora del giorno (Hour).
- **Calcolo delle emissioni di CO₂:** Assumendo un intervallo temporale di osservazione di 5 minuti (1/12 ora), è stata calcolata la distanza percorsa moltiplicando la velocità media del traffico (Traffic_Speed_kmh) per la durata in ore. Successivamente, le emissioni totali di CO₂ (Emission_CO2_total) sono state ottenute come prodotto delle emissioni specifiche per chilometro (Emission_Levels_g_km) e della distanza percorsa.
- **Calcolo del consumo energetico:** Il consumo di carburante per l'intervallo di osservazione è stato calcolato moltiplicando il consumo orario di energia (Energy_Consumption_L_h) per la durata dell'intervallo. Inoltre, è stata effettuata una conversione approssimativa da litri a megajoule (MJ), utilizzando un fattore di conversione di 34.2 MJ per litro di benzina.
- **Definizione delle fasce orarie (time slot):** L'ora del giorno è stata categorizzata in quattro fasce temporali distinte: *morning* (6-12), *afternoon* (12-18), *evening* (18-24) e *night* (0-6). Queste categorie sono state codificate tramite one-hot encoding per consentire l'utilizzo nei modelli.
- **Normalizzazione:** Le feature numeriche di interesse (Vehicle_Count, Road_Occupancy_%, Traffic_Speed_kmh, Emission_Levels_g_km, Energy_Consumption_L_h) sono state scalate utilizzando la tecnica *Min-Max scaling*, riportando i

valori nell'intervallo $[0, 1]$, per consentire il calcolo degli indici.

- **Creazione di variabili di interazione e indici compositi:** Sono state generate nuove feature derivanti dall'interazione tra variabili normalizzate, quali il prodotto tra velocità e occupazione stradale (*Speed_Occupancy_Interaction*) e tra emissioni e consumo energetico (*Emission_Energy_Interaction*). Inoltre, è stato calcolato un indice di congestione (*Congestion_Index*) come combinazione ponderata di conteggio veicoli e percentuale di occupazione stradale, con pesi rispettivamente pari a 0.4 e 0.6.
- **Pulizia finale:** Le feature normalizzate originali sono state rimosse per evitare ridondanze nel dataset finale. Sono state rimosse anche le feature che non erano rilevanti per realizzare i nostri obiettivi di business.




Fig. 5. Boxplot delle nuove feature numeriche

Le nuove feature hanno evidenziato degli outlier Fig. 5 che devono essere rimossi perché vanno ad influenzare l'apprendimento del modello, essendo che usiamo un modello di regressione il quale è robusto ma meno “immune”, quindi può beneficiare di un preprocessing mirato e di una regolazione fine degli iperparametri.

Rimozione degli outlier

Per individuare e rimuovere gli outlier presenti nel dataset, è stata utilizzata una strategia basata sull'intervallo interquartile (IQR) [5], applicata su tutte le variabili numeriche. A differenza dell'approccio standard (che utilizza i quartili $Q1 = 25^\circ$ percentile e $Q3 = 75^\circ$ percentile), si è scelto di adottare dei valori meno sensibili alla presenza di rumore: $Q1 = 30^\circ$ percentile e $Q3 = 70^\circ$ percentile.

L'intersezione logica delle condizioni per ciascuna colonna assicura che vengano mantenute solo le righe prive di outlier in **tutte** le feature numeriche. Il dataset risultante viene quindi utilizzato per la fase di modellazione, garantendo una maggiore robustezza dei modelli predittivi.

D. Modelling Approach

Per affrontare i problemi predittivi proposti è stato adottato un approccio di **Supervised Learning**, in cui i modelli apprendono dalle osservazioni etichettate. In particolare, sono state utilizzate due diverse variabili target:

- *Traffic_Condition* per il task di **classificazione**, con tre classi: Low, Medium, High
- *Emission_CO2_total* per il task di **regressione**, al fine di stimare i livelli di emissioni in grammi per chilometro

Sono stati scelti modelli di ensampling basati su **alberi decisionali**, apprezzati per la loro capacità di gestire dati eterogenei (numerici e categorici), la resistenza agli outlier e la non necessità di normalizzazione preventiva delle feature. In particolare:

- **Random Forest Classifier:** utilizzato per classificare lo stato del traffico in tre classi: Low, Medium, High
- **Random Forest Regressor:** utilizzato per stimare le emissioni veicolari in grammi per km

Suddivisione del Dataset

Per garantire una valutazione robusta delle prestazioni del modello e prevenire fenomeni di overfitting, il dataset è stato suddiviso in tre sottoinsiemi distinti: *training set*, *validation set* e *test set*.

La procedura di splitting è avvenuta in due fasi successive:

- 1) **Prima divisione:** l'80% del dataset è stato riservato per le fasi di training e validazione, mentre il restante 20% è stato isolato come test set finale, utilizzato esclusivamente per la valutazione del modello a posteriori.
- 2) **Seconda divisione:** il sottoinsieme di training+validation (80%) è stato ulteriormente suddiviso, allocando il 75% per il training vero e proprio e il 25% per la validazione dei modelli. Tale ripartizione corrisponde, in termini percentuali sull'intero dataset, a:

- 60% training set,
- 20% validation set,
- 20% test set.

Il validation set è stato utilizzato per la fase di *cross-validation*, al fine di ottimizzare gli iperparametri e valutare la capacità di generalizzazione dei modelli. Tutte le suddivisioni sono state eseguite utilizzando una partizione stratificata (quando applicabile) e fissando il parametro *random_state* per garantire la riproducibilità degli esperimenti.

Task 1: Classificazione dello stato del traffico

Una prima classificazione è stata fatta senza applicare particolari tecniche di miglioramento del modello semplicemente andando ad eliminare delle feature inutili/ridondanti. Al fine di migliorare le prestazioni del modello di classificazione durante la fase di addestramento, sono state implementate due strategie fondamentali: l'analisi dell'importanza delle feature e l'ottimizzazione degli iperparametri.

Feature Importance È stata adottata la tecnica di *Recursive Feature Elimination* (RFE) [1] per la selezione automatica delle variabili più rilevanti. Questo processo consente di identificare un sottoinsieme ottimale di variabili esplicative, riducendo la dimensionalità del problema, migliorando la generalizzazione del modello e minimizzando il rischio di overfitting.

I grafici Fig. 6 Fig. 7 mostrano le feature che hanno più importanza e per i nostri modelli predittivi utilizziamo le 10 migliori




Fig. 6. Feature importance RFE Task 1




Fig. 7. Feature importance RFE Task 2

Visualizzando Fig. 8 i dati e la foresta possiamo vedere che il modello è andato in **overfitting** troppi alberi, troppe foglie profondità eccessiva.

Cosa significa? Il modello ha troppi parametri/regole e si adatta troppo ai dati di partenza. Con il rischio ottime




Fig. 8. Albero Overfittato

performance in training, ma scarse su dati reali.

Per migliorare la capacità predittiva del modello Ss è passati all'utilizzo della:

Ottimizzazione degli Iperparametri Per la sintonizzazione fine degli iperparametri del modello, è stata impiegata una procedura di *Bayesian Optimization* [2]. L'addestramento finale del modello è stato eseguito utilizzando i migliori iperparametri trovati su un set di validazione separato. In particolare i migliori parametri trovati sono: ('max_depth' : 10, 'min_samples_leaf' : 1, 'min_samples_split' : 10, 'n_estimators' : 300)

Task 2: Regressione per stimare la quantità di emissioni

Una prima regressione è stata fatta senza applicare particolari tecniche di miglioramento del modello, andando ad eliminare delle feature inutili/ridondanti. Successivamente il modello è stato addestrato utilizzando Recursive Feature Elimination (RFE) [1] per selezionare automaticamente le variabili più rilevanti nel predire le emissioni di CO, basandosi su un dataset filtrato dagli outlier, Così da migliorare i valori di RMSE e MAE.

VI. RESULTS

In questa sezione vengono presentati i risultati ottenuti attraverso due task principali di apprendimento applicate ai dati di traffico.

Per entrambe le task, i risultati sono stati valutati tramite metriche appropriate: accuracy, precision e F1-score per la classificazione, e MAE/RMSE per la regressione. I risultati ottenuti sono stati poi supportati da visualizzazioni e grafici descrittivi delle prestazioni dei modelli.

Task 1: Classificazione dello stato del traffico

È stato utilizzato un modello RandomForestClassifier addestrato su un insieme di osservazioni storiche con l'obiettivo di prevedere la variabile target Traffic_Condition.

La Tabella I mostra i risultati ottenuti dal modello RandomForestClassifier dopo un processo di ottimizzazione

La **matrice di confusione** Fig. 9 rappresenta la performance di un modello di classificazione con tre classi: Low, Medium, High.

Classe	Precision	Recall	F1-score	Supporto
Classe 0	0.78	0.58	0.67	60
Classe 1	0.75	0.66	0.70	307
Classe 2	0.86	0.94	0.90	633
Macro avg	0.80	0.73	0.76	1000
Weighted avg	—	—	—	—
Accuracy	—	—	0.83	1000

TABLE I
REPORT DI CLASSIFICAZIONE PER IL MODELLO
RANDOMFORESTCLASSIFIER (BASELINE OTTIMIZZATO)




Fig. 9. Matrice di confusione

- **True Positives (TP):**
 - Low: 35
 - Medium: 202
 - High: 592
- **Errori di classificazione:**
 - 25 Low sono stati classificati come Medium.
 - 10 Medium come Low.
 - 95 Medium come High.
 - 41 High come Medium.

Il modello è molto accurato nel classificare la classe **High** (592 corretti su 633). La classe **Medium** ha un numero significativo di errori (110 su 307). La classe **Low** è spesso confusa con **Medium**. Mostra buone prestazioni nella distinzione della classe High, mentre fatica a separare correttamente Low e Medium. Tuttavia, per una classificazione del traffico è preferibile una previsione più pessimistica.

Dataset	Accuracy
Train	0.925
Test	0.829

TABLE II
ACCURATEZZA DEL MODELLO SUI DATI DI TRAINING E TEST

Valutazione delle Prestazioni del Modello

Come si evince dalla Tabella II:




Fig. 10. Albero

- **Train Accuracy:**
Il modello mostra un'elevata accuratezza sui dati di addestramento, suggerendo che ha appreso bene i pattern presenti nel training set.
- **Test Accuracy:**
L'accuratezza sul test è leggermente inferiore rispetto al training, il che è normale. Tuttavia, una differenza di circa 10 punti percentuali può indicare un possibile **inizio di overfitting**, ma **controllato grazie al tuning**.

Cross-Validation Accuracy:

I risultati ottenuti sono:

- **Cross-Validation Accuracy:**
[0.82, 0.832, 0.822, 0.816, 0.82, 0.802, 0.844, 0.818, 0.812, 0.838]
- **Precisione media:** 82.24%
- **Deviazione standard:** 1.18%

Il valore della deviazione standard non è alto né insolito per una cross-validation con 10 fold. Anzi, indica che il modello ha una buona stabilità: l'accuratezza sui vari fold non varia troppo. La Cross-Validation conferma una **performance solida e stabile**: la media è elevata e la bassa deviazione standard suggerisce che il modello si comporta in modo coerente su diversi subset dei dati.

Considerazioni Finali L'ottimizzazione con BayesSearchCV ha portato a:

- **Miglioramento della generalizzazione**, con una buona coerenza tra test e CV.
- **Riduzione del rischio di overfitting**, mantenendo alta l'accuratezza sul training.
- Un modello **più robusto e performante** rispetto alla configurazione predefinita.

Nel complesso, il modello è **affidabile e ben bilanciato**.

Visualizzazione Foresta Dal grafico della foresta Fig. 10 possiamo notare una netta riduzione sia degli alberi della foresta sia del numero di foglie, questo è stato possibile grazie ai parametri individuati dal BayesSearchSV [2]

Analisi della curva ROC




Fig. 11. Curva AUC-ROC

La curva **ROC (Receiver Operating Characteristic)** [4] rappresenta la capacità del classificatore **Random Forest** di distinguere tra le tre classi: Low, Medium e High. In particolare dal grafico Fig. 11 possiamo osservare:

- **Classe Low:** Ottima separazione. Il modello può imparare a riconoscerla molto bene, anche memorizzando specifici pattern (overfitting), essendoci poche istanze.
- **Classe Medium:** Buona separazione, ma leggermente inferiore rispetto alle altre classi, risulta più difficile da distinguere con precisione.
- **Classe High:** Prestazione elevata. La curva è vicina all'angolo in alto a sinistra del grafico; il modello è abbastanza capace di riconoscere la classe, anche grazie alla presenza di molte istanze che la rappresentano.

Assi del grafico:

- **Asse X (False Positive Rate):** Tasso di falsi positivi.
- **Asse Y (True Positive Rate):** Tasso di veri positivi.

La **linea diagonale tratteggiata** rappresenta una classificazione casuale ($AUC = 0,5$). Le curve che si trovano sopra questa linea indicano che il classificatore ha buone capacità predittive.

Il modello Random Forest mostra ottime performance nel classificare tutte le classi, con AUC elevati.

Task 2: Regressione per stimare la quantità di emissioni

E' stato utilizzato il modello `RandomForestRegressor`. La Tabella III mostra i risultati ottenuti dal modello `RandomForestRegressor` dopo un processo di ottimizzazione.

Performance del Modello con RFE (scala: 2 398)

- **Errore RMSE (181,5)** su un range di 2 398 corrisponde a un **errore medio quadratico inferiore all'8%**, segno di **ottima accuratezza** su tutta la scala delle emissioni.
- **Errore MAE (137,1)** su un range di 2 398 è circa il **6%**, riflettendo un errore assoluto **molto contenuto** in media.
- L' **R^2 Test (0,894)** indica che ben il **89,4% della varianza** nelle emissioni è spiegato, su un range ampio di possibili valori.

Metrica	Valore	% rispetto al range
R^2 Train	0,9400	—
R^2 Test	0,8940	—
RMSE Test	181,52	$181,52 / 2\,398 \approx 7,6\%$
MAE Test	137,13	$137,13 / 2\,398 \approx 5,7\%$

TABLE III
REPORT DI REGRESSIONE PER IL MODELLO `RANDOMFORESTREGRESSOR`
(BASELINE OTTIMIZZATO)




Fig. 12. Grafico a dispersione delle previsioni

Complessivamente:

- Il modello, grazie alla **RFE**, è estremamente performante sulla **scala completa del fenomeno**, con errori che coinvolgono meno del **10% del range totale**.
- Questo conferma la **solidità e l'affidabilità** del modello anche in condizioni diverse (es. casi di emissioni basse o elevate).

Conclusione

- Il modello pre-RFE era già **affidabile**, ma presentava **errori maggiori** in relazione all'intera **scala delle emissioni**.
- Con RFE, il modello ha ottenuto un **chiaro miglioramento** in tutti gli indicatori, **riducendo gli errori e aumentando la spiegazione della varianza**.
- Questo dimostra che la **selezione automatica delle feature** ha portato a un modello **più efficiente, preciso e generalizzabile**.

Nota finale: Usare la scala del fenomeno (min-max) per leggere le metriche permette una valutazione **più concreta** dell'errore e dell'affidabilità del modello nel suo contesto reale.

Analisi del Grafico a Dispersione: Valori Reali vs Predetti

Il grafico a dispersione a Fig. 12 mostra la relazione tra i valori reali delle emissioni di CO₂ e i valori predetti dal modello Random Forest. Questo tipo di grafico è fondamentale per valutare visivamente l'accuratezza e la performance di un modello di regressione.

Componenti del grafico:

- **Punti blu (Previsioni):** ogni punto rappresenta una coppia (valore reale, valore predetto). Idealmente, tutti i punti dovrebbero cadere sulla linea di *previsione perfetta*.
- **Linea rossa tratteggiata (Previsione perfetta):** rappresenta la situazione ideale in cui i valori predetti corrispondono esattamente ai valori reali ($y = x$). Serve da riferimento per valutare lo scostamento delle previsioni dalla perfezione.
- **Linea blu continua (Retta di regressione):** rappresenta la retta di regressione lineare che meglio si adatta ai punti delle previsioni. La sua vicinanza alla linea rossa indica la bontà dell'adattamento del modello.

Osservazioni chiave:

- **Concentrazione attorno alla linea di previsione perfetta:** la maggior parte dei punti si raggruppa strettamente attorno alla linea rossa tratteggiata, in particolare per valori reali più bassi. Questo è un segnale di alta accuratezza predittiva.
- **Comportamento ai valori estremi:** per emissioni superiori a 1500, si osserva una maggiore dispersione. Il modello tende a sottostimare questi valori (i punti cadono al di sotto della linea rossa). Per valori molto bassi, si nota talvolta una leggera sovrastima.
- **Confronto tra le linee:** la retta di regressione (blu) è molto vicina alla linea di previsione perfetta (rossa), confermando una buona aderenza media delle previsioni. Una leggera inclinazione può suggerire una tendenza sistematica alla sottostima o sovrastima ai poli estremi.

Interpretazione:

- **Buona performance generale:** il modello Random Forest mostra una performance complessivamente elevata nella previsione delle emissioni. La correlazione tra valori reali e predetti è forte e visivamente evidente.
- **Precisione variabile:** la precisione del modello non è costante su tutta la scala: migliora nel range centrale ma cala leggermente agli estremi. Ciò suggerisce un possibile margine di miglioramento nella gestione dei casi più rari o estremi.

Analisi grafo Andamento Temporale delle Emissioni CO₂: Reale vs Predetto

Il grafico a Fig. 13 visualizza l'andamento dei valori reali delle emissioni di CO₂ rispetto ai valori predetti dal modello, lungo l'indice dei campioni. Questo tipo di visualizzazione è utile per osservare come il modello si comporta sequenzialmente e per individuare eventuali tendenze o pattern non catturati.

Componenti del grafico:

- **Linea blu (Valori Reali):** rappresenta la serie storica dei veri valori delle emissioni di CO₂.




Fig. 13. Grafico sull'andamento delle emissioni

- **Linea arancione (Valori Predetti):** rappresenta la serie storica dei valori previsti dal modello.
- **Asse X (Indice Campione):** indica l'ordine sequenziale dei campioni nel dataset.

Osservazioni chiave:

- **General Good Fit:** a una prima occhiata, la linea arancione dei valori predetti segue fedelmente l'andamento della linea blu dei valori reali. Il modello sembra catturare la maggior parte delle fluttuazioni.
- **Smoothing Effect:** la linea delle previsioni è generalmente più "liscia" rispetto a quella dei valori reali. I picchi nei dati reali sono spesso sottostimati, e le valli profonde non sempre raggiunte con precisione.
- **Differenze nei Picchi e Valli:** nei punti con picchi elevati (es. intorno all'indice 200, 450, 600, 700), il modello tende a predire valori inferiori. Lo stesso avviene nelle valli profonde.
- **Coerenza nell'Andamento:** nonostante alcune discrepanze, il modello replica il trend generale e le possibili ciclicità. L'ampiezza delle fluttuazioni è simile, seppur con varianza ridotta.

VII. DISCUSSION & CONCLUSION

A. Valutazione qualitativa delle predizioni

Per valutare la coerenza e l'affidabilità del modello in scenari realistici, sono stati generati manualmente tre casi sintetici rappresentativi di differenti condizioni di traffico: favorevoli, intermedie e critiche.

I risultati mostrano che il modello è in grado di classificare correttamente situazioni critiche con elevata confidenza, evidenziando una buona sensibilità verso le condizioni ad alta congestione. Tuttavia, nei casi con condizioni favorevoli o intermedie, si osserva una certa incertezza nella discriminazione tra le classi Low e Medium, con distribuzioni di probabilità meno nette.

Questa tendenza può indicare una soglia decisionale non perfettamente calibrata o una sovrapposizione tra le distribuzioni delle feature nelle fasce meno critiche. In particolare, la classe Low risulta essere talvolta sottostimata anche in presenza di indicatori favorevoli.

Nel contesto del traffico urbano, una predizione ottimistica ("Low") errata può avere conseguenze peggiori rispetto a una predizione pessimistica infatti predire Low quando la situazione è in realtà Medium o High può malgestione dei flussi, sottostima del rischio di congestione o incidenti. Nel

complesso, il modello mostra una buona capacità di generalizzazione, in particolare per le condizioni ad alta severità.

B. Valutazione delle prestazioni del modello di regressione

Il modello di regressione sviluppato ha mostrato una buona capacità predittiva sia sul dataset di addestramento sia su quello di test. Il coefficiente di determinazione (R^2) indica che la maggior parte della varianza della variabile target è stata spiegata dal modello, con valori elevati in entrambe le fasi.

Le metriche di errore, quali il *Root Mean Squared Error* (RMSE) e il *Mean Absolute Error* (MAE), confermano un buon livello di accuratezza nelle previsioni su dati non visti, suggerendo un'efficace generalizzazione.

È possibile che la presenza di valori anomali influenzi maggiormente alcune metriche di errore; pertanto, un'analisi approfondita degli errori residui potrebbe essere utile per migliorare ulteriormente le prestazioni del modello.

Analisi spaziale delle emissioni: identificazione delle zone critiche

Per completare l'analisi quantitativa del modello di regressione, è stata condotta una visualizzazione geospaziale delle emissioni stimate di CO₂. La mappa risultante consente di identificare le aree geografiche con i livelli di emissione più elevati, fornendo un supporto concreto per il monitoraggio ambientale e la pianificazione urbana.

La figura Fig. 15 mostra una mappa di calore interattiva che evidenzia le zone critiche a livello urbano, in base alla media delle emissioni stimate. Le coordinate sono state aggregate su gruppi geografici (latitudine e longitudine) per favorire la leggibilità. Le 10 zone con emissioni medie più alte sono riportate nella tabella seguente:

Lat	Lon	CO ₂ (g/km)
40.835	-73.981	2103.94
40.611	-73.811	2055.36
40.794	-73.928	2032.47
40.681	-73.852	2025.67
40.727	-73.925	2012.49
40.725	-73.971	2009.16
40.639	-73.756	1999.47
40.748	-73.708	1990.90
40.821	-73.743	1989.89
40.787	-73.755	1987.58

Top 10 zone con emissioni medie stimate più elevate.

Questa rappresentazione visiva contribuisce a una comprensione più immediata e localizzata delle problematiche ambientali, offrendo un ulteriore elemento per valutare la validità e l'utilità del modello predittivo sviluppato. Fornendo un importante supporto alla pianificazione urbana, consentendo di concentrare gli sforzi di mitigazione nelle aree più impattate.




Fig. 15. Mappa di calore delle emissioni di CO₂ stimate

- [3] Luis Moreira-Matias and et al. Predicting traffic behavior using social media. *IEEE Transactions on Intelligent Transportation Systems*, 14(3):1543–1552, 2013.
- [4] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in python, 2011. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_auc_score.html.
- [5] John W. Tukey. Exploratory Data Analysis, 1977. Capitolo dedicato alla regola del 1.5×IQR per individuare outlier.
- [6] Bing Yu, Haoteng Yin, and Zhanxing Zhu. Spatio-temporal graph convolutional networks: A deep learning framework for traffic forecasting. *IJCAI*, 2018.
- [7] Ziya. Smart mobility traffic dataset: Cyber-physical social network data for intelligent traffic management. <https://www.kaggle.com/datasets/ziya07/smart-mobility-traffic-dataset/data>, February 2025.

REFERENCES

- [1] Isabelle Guyon, Jason Weston, Stephen Barnhill, and Vladimir Vapnik. Gene selection for cancer classification using support vector machines. *Machine learning*, 46(1):389–422, 2002.
- [2] Thomas Head, MechCoder, Gilles Louppe, Iaroslav Shcherbatyi, fcharras, Michael Vincent, Julian Zimmert, Balaji Krishnakumar, pfistfl, Emil Hvitfeldt, et al. Scikit-optimize: Sequential model-based optimization with a Scikit-Learn interface. <https://scikit-optimize.github.io/>, 2018. Accessed: 2025-06-25.